

臺北市立大學 資訊科學系碩士、國立臺灣科技大學 資訊工程系學士

具 AI 應用於法律領域的研究與專案經驗，熟悉 RAG 框架設計與 LLM 微調，能獨立完成從 PoC 驗證到可用原型的系統開發。

Email：lawrencechh.cs@gmail.com

手機：+886-975-693-561

自我介紹

您好，我是黃千翔，擁有三年的 LLM 開發經歷，自 ChatGPT 崛起前便投入自然語言，專長是覺察使用者需求，設計並建構完整的 AI 解決方案，主要研究將 AI 應用於法律領域。

我開發過的專案包含三大類型，結構化資料、預訓練及微調語言模型、RAG 問答框架。

- **結構化資料**：曾與法律專家討論，依據其定義的抽象概念，與 AI 協作 (微調模型或 API)，從文件中提取符合定義的資訊，建置結構化資料庫。此外，也曾觀察大量文件，從中定義抽象概念後，微調分類及摘要模型。
- **預訓練及微調語言模型**：繁中資料集預訓練增加模型知識，並定義微調任務及建置微調資料集，讓模型學習運用知識，微調過法律見解問答模型、LLaMA3.2-1B-instruct 模型協作建置生成資料集。
- **RAG 問答框架**：從實證研究者角度發想需求，並與法律專家討論，設計結合傳統關鍵字搜尋及向量搜尋的問答流程，以協助法律工作者從大量見解資料中，快速整理可靠來源的研究素材，解決使用者的實際痛點。

我希望能善用我的資訊專業、跨領域學習能力，協助團隊導入 AI 解決方案並累積更多實務經驗。

專業技能

- **LLM 與生成式 AI**
 - 模型與生態系：LLaMA、TAIDE、ChatGLM、Breeze、PyTorch、Transformers、Hugging Face、LLaMA Factory
 - 向量搜尋與問答：FAISS、Elasticsearch、ChatGPT / OpenAI API
 - 資料處理與評估：pandas、CKIP、正則表達式、ROUGE、BLEU、matplotlib
- **模型部署與服務開發**
 - 後端開發：Python、FastAPI、Django
 - 前端：Gradio
 - DevOps：Docker、Git、GitHub
- **AI 解決方案設計**
 - 需求分析、RAG 架構設計、語言模型微調與應用、跨領域協作、PoC / 原型系統開發

專案目錄

- **第3頁** 裁判觀點檢索平台 (RAG) Phase 3: 基於RAG的法院見解檢索與問答框架
 - **第4頁** 裁判觀點檢索平台 (RAG) Phase 2: 刑事、民事判決資料庫系統
 - **第5頁** 裁判觀點檢索平台 (RAG) Phase 1: 台灣地圖上的見解資料庫
 - **第6頁** LLaMA3.2-1B-Instruct 繁中指令微調: 多任務基底模型訓練 (微調)
 - **第7頁** 法院見解問答機器人 (微調)
 - **第8頁** 預訓練模型在少資源環境下的摘要能力：以交通過失傷害判決書為例 (微調)
 - **第9頁** 使用ChatGPT自動化資料標註之架構，以刑事判決書中的事實為例 (提示工程)
-

專案摘要

1. 裁判觀點檢索平台 (RAG)

- 自「台灣地圖上的見解資料庫」起步，微調 ChatGLM 模型以提取向量特徵，並應用於民事見解資料搜尋，專案獲經濟部科技新秀大賽亞軍。
- 進一步建置「裁判觀點檢索平台」，使用地端模型 ChatGLM-2 結合正則表達式，自數百萬筆判決書中提取裁判日期、涵攝、法院見解等結構化資訊，並以 FastAPI 與 Elasticsearch 建立資料庫搜尋服務。
- 在此基礎上設計 RAG 問答框架，整合關鍵字搜尋與向量搜尋 (bge-m3) 的問答功能。
- 與法律工作者反覆訪談需求，改善問答流程與回覆模板，協助使用者快速找到案件相關的法官見解，並提供附來源的回答提升信賴感。

2. LLaMA3.2-1B-Instruct 繁中指令微調：多任務基底模型訓練 (微調模型)

打造精通繁體中文且低幻覺的1B模型，透過多樣化指令微調，強化繁中能力並抑制幻覺，可作為客製化 ETL 解決方案及提升 RAG 搜尋準確性。

3. 法院見解問答機器人 (微調模型)

利用預訓練及微調 TAIDE 模型 (LLaMA2 & LLaMA3 架構)，讓民眾能以直觀方式釐清法院見解中的抽象概念。

4. 預訓練模型在少資源環境下的摘要能力：以交通過失傷害判決書為例 (微調模型)

提出兩階段摘要流程，利用微調 ChatGLM-6B 模型進行分類與摘要，在少量資料下有效提升模型摘要準確性。

5. 使用ChatGPT自動化資料標註之架構，以刑事判決書中的事實為例 (LLM 應用)

驗證 ChatGPT 輔助標註專業領域資料的可行性，透過明確步驟與迭代參考，建立高品質分類資料集，提升標註效率與準確性。

裁判觀點檢索平台 (RAG)

- 專案概述 微調 LLM 自數百萬筆判決書提取結構化資訊，並建構後端資料庫系統。與法律專家合作探索問答框架，引入 RAG 技術，最終發展為協助法律實證研究與法律工作者日常工作的問答型知識系統。

Phase 3: 基於RAG的法院見解檢索與問答框架

- 目標
以裁判書見解為來源的問答系統，協助法律工作者搜尋、篩選、解釋見解資料，從中取得實證研究的素材。
- 成果 (Link)
 - 與法律工作者合作，設計問答流程，使 AI 應用能解決實際痛點。
 - 採用關鍵字與向量混合搜尋，提升 RAG 回答的準確度。
 - 附加參考來源的回答，提升使用者信賴感。
 - 整合 Phase 2 的搜尋系統，使平台功能更完整。
 - 目前累積超過 2,000 次使用。
- 方法
 - 分析使用者需求，並與法律工作者協作，探索最佳問答流程。
 - 採用 Elasticsearch 為向量資料庫，地端 bge-m3 模型製作高效精準的見解向量，支援大量裁判書的搜尋與匹配。
 - 設計提示工程與問答流程：使用者輸入、選擇參考資料來源、AI 問答、AI 整理關鍵字、後端關鍵字及向量搜尋、AI 提供附來源的回答。
 - RAG 使用關鍵字過濾大量判決書，並用向量排序過濾結果，提高搜尋效率與回答準確度。
- 工具
 - Python: Pandas, Hugging Face, ChatGPT API
 - Backend: Elasticsearch
 - Other: GitHub, Docker



基於RAG的法院見解檢索與問答框架

Phase 2: 刑事、民事判決資料庫系統

- 目標

協助建置刑事、民事判決資料庫系統，採用 AI 模型輔助結構化判決書，使判決書裡的見解、心證、涵攝資訊一目了然，達成監督司法之效。

- 成果

- 資料前處理百萬筆刑事民事判決書，善用地端 LLM 提取結構化資訊。
- 後端資料庫與搜尋功能建置。
- 與前端合作，提供詳細 API 文件，確保前端開發流程順暢。

- 方法

1. 使用正則表達式、經微調的 ChatGLM-2 模型自刑民事判決書提取基本資訊、見解、心證、涵攝。
2. 針對 RAM 用量與搜尋效率，實驗不同資料庫組合(csv、MongoDB、MongoDB結合ElasticSearch、Elasticsearch)，提升搜尋速度、確保高併發數。
3. 設計資料庫架構，並以 FastAPI 實踐後端資料庫與搜尋功能。
4. CKIP 斷詞製作法律關鍵字資料庫，並添加至 Elasticsearch 字典，提高關鍵字搜尋精準度。

- 工具

- **Python:** Pandas, Hugging Face, re
- **Backend:** FastAPI
- **Database:** MongoDB, Elasticsearch
- **Other:** ChatGLM-2, GitHub, Docker, CKIP



裁判觀點檢索平台

Phase 1: 台灣地圖上的見解資料庫

- 目標
 - 受邀參與比賽，開發一個創新且高效的見解資料庫，結合搜尋與語言模型技術，提供使用者更準確且相關性更高的搜尋體驗。
- 成果 (Link)
 - 經濟部科技新秀大賽亞軍
 - 提取微調模型的向量特徵提高搜尋的精確度。
 - 建置完整資料庫系統、簡易前端呈現結果。
- 方法
 - 1. 應用團隊成員微調後的模型、正則表達式，提取結構化資訊 (民事法院見解)。
 - 2. 採用微調後的 ChatGLM 模型特徵（4096維向量），取代主流 OpenAI embedding（1536維），提供更精準的見解相似性搜尋結果。
 - 3. 以 Django 建置後端搜尋系統，包括向量資料、法院見解、與基本資訊，並實現向量與關鍵字搜尋功能。
 - 4. 採用原生 FAISS 向量資料庫解決當時 LangChain 客製化功能不足的問題。
- 工具
 - Python: Pandas, Hugging Face, re
 - Frontend: HTML, CSS, JavaScript, jQuery, Bootstrap
 - Backend: Django, ngrok, FAISS
 - Other: ChatGLM, GitHub, Docker

AIFR的法務好夥伴 - 見解資料庫

涵蓋2016/08-2018/12最高及高等法院民事判決

關鍵字見解查詢

搜尋關鍵字 搜尋見解

查詢內容: 查：○證券交易市場首重誠信，故各項交易條件應為真實，而如要求投資人舉證其係以財務報告內容作為投資依據或重要資料，顯屬困難，就此美國法院曾以集團訴訟之背景為動力，結合市場效率理論（半強勢semistrongform）發展出所謂「詐欺市場理論」，將行為人「故意」以虛偽不實之資訊公開於市場之中，視為對整體市場的詐欺行為，而市場投資人可以「以信賴市場之股價」為由，說明其間接信賴了公開之資訊，故投資人無須一一證明個人之「信賴關係」，即推定其已就交易因果關係盡舉證之責

每頁顯示 10 條 華 搜尋表格

院別	裁判日期	案號	距離	頻率	見解
臺灣高等法院	20160816	臺灣高等法院 101 年度金上字第 23 號民事判決	0.00	1	查：○證券交易市場首重誠信，故各項交易條件應為真實，而如要求投資人舉證其係以財務報告內容作為投資依據或重要資料，顯屬困難，就此美國法院曾以集團訴訟之背景為動力，結合市場效率理論（半強勢semistrongform）發展出所謂「詐欺市場理論」，將行為人「故意」以虛偽不實之資訊公開於市場之中，視為對整體市場的詐欺行為，而市場投資人可以「以信賴市場之股價」為由，說明其間接信賴了公開之資訊，故投資人無須一一證明個人之「信賴關係」，即推定其已就交易因果關係盡舉證之責
臺灣高等法院	20171031	臺灣高等法院 104 年度金上字第 14 號民事判決	267.35	1	惟查，美國證券詐欺民事訴訟實務所謂「詐欺市場理論」，簡言之，係將行為人以虛偽不實之資訊公開於股票交易市場之行為，視為對整體市場之詐欺行為，進而推定任何參與股票交易之善意取得人或出賣人，均信賴公開資訊之真實性，使投資人無須逐一證明個人對公開資訊有信賴關係，且法院往往在被害人證明信賴後，即認為因果關係之要件已滿足
臺灣高等法院臺南分院	20180621	臺灣高等法院臺南分院 106 年度金上字第 1 號民事判決	323.53	1	關於買賣投資行為與不實財報間之因果關係，基於股票價值之認定與一般商品不同，無從依外觀認定其價值，往往須參酌公司過往經營績效、公司資產負債、市場狀況等資訊之揭露，使市場上理性之投資人得以形成判斷；於投資人買進或賣出時，此不實消息已有效反應於股價上，故依「詐欺市場理論」，不論投資人是否閱讀此不實財報均推定其信賴此財報而有交易因果關係，固無待舉證；但投資人仍須證明損害及其金額與不實財報間之因果關係（最高法院104年度台上字第225號判決參照）

台灣地圖上的見解資料庫

LLaMA3.2-1B-Instruct 繁中指令微調: 多任務基底模型訓練 (微調)

- 目標
設計升維 (詳細回答)、降維微調任務 (摘要)，讓模型善用**繁體中文預訓練知識**，未來可作為基底模型，以多任務的微調資料集，使此1B模型協助生成對應任務的資料集。
- 成果
 - 精通繁體中文且低幻覺的1B模型
 - 以多任務微調資料集，精煉小型語言模型繁體中文能力，並有效抑制幻覺，突破了小型模型在繁體中文理解和生成方面的效能瓶頸。
 - 極具潛力的ETL客製化解決方案
 - 兼顧繁中品質的1B模型高效推理速度，可協助建置結構化資料集。
 - 善於學習多樣化中文任務的基底模型。
 - 製作熟悉中文的精準向量，使RAG搜尋結果更可靠。
- 方法
 - 使用 LoRA, Galore 在消費級顯卡 (RTX 4090) 預訓練中文資料，提升模型中文知識。
 - 設計多任務訓練目標 (詳細回答、摘要、中翻英、抑制幻覺...等等)，使模型善於應用中文知識降低幻覺。
 - 實踐資料集生成框架，用 ChatGPT API 生成多任務、問答資料集，並用於微調 LLaMA3.2-1B-Instruct 模型。
- 工具
 - Python:** Pandas, ChatGPT API, Galore, LoRA
 - Other:** LLaMA Factory, GitHub, Docker

問題	原始1B模型	微調模型	解釋
毛澤東在天文有什麼研究成果?他是專家嗎?	毛澤東在天文方面的研究成果不多，但他確實是天文學的熱情追求者。他曾經參與了一些天文研究計畫，並在一些研究中發表了自己的論文。 一個重要的研究成果是毛澤東在1930年代與西方天文學家們合作的《天文學》上發表了一篇論文，題目是「關...	毛澤東並未在天文領域進行任何研究成果。毛澤東主要在政治和社會學領域著名，而非天文學領域。他在學術界的研究和影響主要集中在中國革命歷史和社會主義經濟體制的發展上。	未經過幻覺抑制的模型，只要看到可能的詞彙，就會不斷接龍，微調模型則學會判斷後在回答。
你知道半導體怎麼設計嗎	半導體設計是一個複雜的過程，涉及多個步驟和技術。下面是一個簡單的概述： **步驟** 1. **概念設計** ：designers design the overall concept of the circuit, including the function, performance, and power consumption requirements. 2. **gate design** ：designers create the layout of the gate arrays, which are the building blocks of the circuit.(下略)	半導體的設計是一個複雜的過程，涉及數位和物理學的交集。以下是一個概述，從最基本的概念到設計流程： 1. **需求分析** ：設計始於了解用戶的需求和需求特性。這包括對功能的定義、性能要求、和市場競爭的分析。 2. **系統架構選擇** ：設計者會根據需求分析來決定系統的架構。這包括選擇硬體架構（如晶片、軟體），選擇系統層的結構（如平臺、API），以及決定的數據傳輸方式。(下略)	原始模型對半導體有概念，但中文資料不足夠，因此他只能用英中夾雜的方式回答。

LLaMA3.2-1B-Instruct 繁中指令微調問答

法院見解問答機器人 (微調模型)

- 目標
 - 法院見解多屬抽象概念，民眾難以理解與應用。
 - 透過預訓練語言模型學習法律專門知識，並進行微調，使模型能以自然語言提供見解解釋。
 - 讓使用者以直覺問答方式掌握法院見解，提升法律資訊透明度。
- 成果
 - 預訓練補充模型法律知識，搭配問答集微調後，模型能穩定回答法院見解的概念性問題。
 - 相似度計算與 ROUGE／BLEU 等指標顯示，新舊版 TAIDE 模型效能相近，皆達可用水準。
 - 法條引用仍存在幻覺現象，已提出以資料去重、強化標註與限制生成策略等作為後續改良方向。
- 方法
 - 實驗設計與評估
 - 設計實驗條件與評估指標，系統性比較不同模型與訓練配置的表現。
 - 規劃整體預訓練與微調策略，定義資料提取與生成流程。
 - 模型訓練與微調
 - 採用 LLaMA2 與 LLaMA3 架構模型 (TAIDE-2、TAIDE-3)，以約 30 萬筆 2021 年判決書見解資料進行接續預訓練，系統性強化模型對法律語料與見解脈絡的掌握。
 - 負責設計並實作資料提取與問答生成流程，透過 ChatGPT 建立約 1,800 筆見解相關問答資料集，用於微調模型，使模型具備應用法學知識的能力。
 - 模型表現
 - 使用 ROUGE、BLEU 等自動化指標進行初步效能評估，結果顯示 TAIDE-2 與 TAIDE-3 在目標任務上的表現相近。
 - 實測顯示模型在見解概念性問題上具穩定回答品質，但在精確引用法條時仍有幻覺情形，作為後續調整重點。
 - 改進方向
 - 規劃針對訓練資料進行去重與清洗，只保留具代表性的法院見解，以降低噪音並提升模型回答的一致性與準確度。
 - 設計以 AI Agent 生成高品質見解問答集，並由人工作最後篩選，建立可持續擴充、且品質可控的標註與資料生產流程。
- 工具
 - Python: Pandas, Hugging Face, ChatGPT API
 - Other: LLaMA Factory, GitHub, Docker

	name	predict_bleu-4	predict_rouge-1	predict_rouge-2	predict_rouge-l	predict_runtime	predict_samples_per_second	predict_steps_per_second
VER	0 TAIDE-3_finetune_prefix_finetune_temp0.1	22.368	39.964	19.976	33.164	204.459	0.978	0.245
	1 TAIDE-3_finetune_prefix_finetune_temp0.6	21.586	39.109	19.247	31.937	228.301	0.876	0.219
	2 TAIDE-3_finetune_prefix_finetune_temp0.95	20.070	37.543	17.873	30.732	229.299	0.872	0.218
	3 TAIDE-3_pretrain_half-instruct_finetune_temp0.1	22.408	40.144	20.520	32.937	285.425	0.701	0.175
	4 TAIDE-3_pretrain_half-instruct_finetune_temp0.6	22.163	39.481	19.937	32.530	255.589	0.783	0.196
	5 TAIDE-3_pretrain_half-instruct_finetune_temp0.95	20.355	38.840	18.348	31.126	224.676	0.890	0.223
	6 TAIDE-2_temp0.1	5.934	21.936	6.650	14.147	689.414	0.290	0.073
	7 TAIDE-2_temp0.6	5.937	22.309	6.737	14.543	753.912	0.265	0.066
	8 TAIDE-2_temp0.95	5.620	21.026	6.072	13.942	704.376	0.284	0.071
	9 TAIDE-3_temp0.1_llama3	4.894	19.782	5.465	12.947	885.074	0.226	0.056
	10 TAIDE-3_temp0.6_llama3	4.644	19.236	5.130	12.813	880.613	0.227	0.057
	11 TAIDE-3_temp0.95_llama3	4.829	19.641	5.390	13.075	854.858	0.234	0.058
	12 TAIDE-2_pretrain_half-instruct_finetune_temp0.1	18.872	38.978	19.471	31.481	340.478	0.587	0.294
	13 TAIDE-2_pretrain_half-instruct_finetune_temp0.6	18.651	38.540	19.065	31.137	319.238	0.626	0.313
	14 TAIDE-2_pretrain_half-instruct_finetune_temp0.95	17.330	36.602	16.645	29.508	159.591	1.253	0.313
	15 TAIDE-2_pretrain_finetune_temp0.1	21.718	40.422	20.730	33.146	289.672	0.690	0.345
	16 TAIDE-2_pretrain_finetune_temp0.6	21.378	39.473	20.045	32.447	273.842	0.730	0.365
	17 TAIDE-2_pretrain_finetune_temp0.95	19.865	39.013	18.800	31.742	156.630	1.277	0.319


法院見解問答機器人微調

預訓練模型在少資源環境下的摘要能力：以交通過失傷害判決書為例

- 目標
 - 判決書冗長，法律工作者需花費大量時間閱卷。
 - 藉由 AI 技術從判決書中提取重點資訊，節省閱卷時間。
 - 使用預訓練模型的基礎知識，克服專門領域知識稀缺的困境。
- 成果 (Link)
 - 跨領域學習刑法知識，與法律專家合作建置分類資料集。
 - 與微調的分類模型人機協作，提高人類標註的效率與準確度。
 - 提出兩階段摘要流程，解決模型輸入長度不足、專門領域資料不足的困境。
- 方法
 1. 兩階段摘要流程：

初步篩選：微調大參數生成模型 ChatGLM 於分類任務，將精細類別合併為廣泛類別 (摘要、無關) 以減少句子特徵衝突，並有效縮短判決書長度。


生成摘要：將與摘要有關的句子輸入微調的 ChatGLM 摘要模型，生成簡潔、高品質摘要 (事實、爭點、心證、量刑考量、訴訟要件不足)。
 2. 使用 ROUGE, BLEU 方法驗證生成模型在分類及摘要任務等6種組合下的表現。
- 工具
 - **Python:** Pandas, Matplotlib, ROUGE, BLEU, Hugging Face, LLaMA Factory
 - **Other:** ChatGLM, GitHub



兩階段判決書摘要流程圖

使用ChatGPT自動化資料標註之架構，以刑事判決書中的事實為例

- 目標
 - 構成要件該當性為法官審判案件的第一道關卡，藉由找出判決書中的客觀構成要件行為，可協助分類判決書，協助民眾快速找到關聯案件。
 - 建立一個自動化標註架構，從刑事判決書中找出客觀構成要件行為（案例：殺人行為）。
 - 驗證 ChatGPT 是否能在提供明確定義與步驟的前提下，協助人類標註專門領域資料，提高效率與準確性。
- 成果 [\(Link\)](#)
 - 與法律專家合作建置專門領域資料集，以評估模型準確度達 86%。
 - 設計自動化標註資料流程，並善用提示工程確保模型輸出的一致性與精確性。
 - 應用 ChatGPT 在無提供 API 的情況下，人機協作以提升標註效率。
- 方法
 1. 跨領域學習刑法知識，並設計提示工程，整理殺人罪構成要件定義與判斷步驟，讓 ChatGPT 能準確辨認間接行為，例如：「XXX以打火機點燃抱枕，引發火災」。
 2. 使用 Python 與 Selenium 自動化瀏覽器控制來標註資料，分類判決書中的句子是否包含殺人行為。
 3. 與法律專家合作設計有效的標註規則，運用 Pandas 統整結果，並以 Matplotlib 視覺化分析與評估 ChatGPT 的標註表現。
- 工具
 - **python**: Selenium, Pandas, Matplotlib



ChatGPT分類表現